

Geometría de la Información

Un mapa para comparar modelos



Índice general

Prólogo	1
0.1 Álgebra lineal	5
0.2 Cálculo multivariable	6
0.3 Probabilidad (convergencias, LLN/CLT)	7
0.4 Estadística matemática	8
0.5 Análisis convexo y optimización	9
0.6 Geometría diferencial	10
0.7 Teoría de la información	11
0.8 Procesos estocásticos	11
0.9 Programación científica	12
0.10 Métodos numéricos para optimización	13

Prólogo

«Tu única brújula fiable es la curvatura de tu propia incertidumbre.»

Este libro arranca desde una tensión que ya vives si haces estadística, ciencia de datos o modelas un fenómeno: el mundo sigue una ley desconocida $p(x)$ (la **verdad**) y tú trabajas con una familia de modelos $q_\theta(x)$ (tu **aproximación**). El objetivo operativo no es *adivinar la verdad*, sino elegir y ajustar q_θ para que el *desajuste* sea lo bastante pequeño como para tomar buenas decisiones.

Para evitar ambigüedades, usaremos una convención fija:

- **Verdad:** $p(x)$.
- **Modelo:** $q_\theta(x)$ (parámetro θ).
- **Prior/Posterior:** $\pi(\theta)$ y $\pi(\theta | x)$.
- **Divergencia KL:** $D_{\text{KL}}(p||q)$.

Bayes da la receta de actualización cuando llega evidencia:

$$\pi(\theta | x) \propto \pi(\theta) q_\theta(x).$$

La geometría de la información (GI) no compite con esto: le da *coordenadas, regla de medir y rutas rectas* al espacio de distribuciones para que comparar y optimizar deje de depender de cómo escribas el modelo.

Entrada filosófica (en una línea)

Medir *qué tan lejos* están dos distribuciones *ya* es tomar una postura normativa sobre *qué* consideras estar *cerca de la verdad*. Todo lo demás —métricas, conexiones duales, variedades dualmente planas— nace de esa decisión mínima: usar una regla de medir que no se rompa al cambiar de coordenadas equivalentes.

¿Qué es reparametrizar (y por qué importa)?

Cambiar de coordenadas para trabajar mejor *sin cambiar la información*: probabilidad $\pi \in (0, 1) \Rightarrow \text{logit } \eta = \log(\pi/(1 - \pi))$; varianza $\sigma^2 > 0 \Rightarrow \text{precisión } \tau = 1/\sigma^2$; parámetro positivo $\lambda > 0 \Rightarrow u = \log \lambda$. La conclusión de fondo *no* debería cambiar. GI exige y formaliza esa coherencia.

Qué añade GI y por qué importa (la promesa concreta)

1. **Una métrica seleccionada por invariancia (Chentsov).** Pedir que *las distancias no cambien* al usar estadísticos suficientes fija (salvo constante) la métrica de Fisher–Rao. Un representante típico:

$$g_{ij}(\theta) = \mathbb{E}_\theta[\partial_i \log q_\theta(X) \partial_j \log q_\theta(X)].$$

La sensibilidad depende de la información, no de tus coordenadas.

2. **Dos rectas canónicas (dualidad e/m).** En familias exponenciales, el espacio es dualmente plano: hay dos *geodésicas* naturales. Una preserva promedios (coordenadas de expectativa); la otra, parámetros naturales. Esto explica dos maneras legítimas de actualizar y *cuándo* conviene cada una.
3. **Proyecciones por KL y pitagórico.** Aproximar p con una familia $\mathcal{Q}$ se hace proyectando por KL. Aparece la descomposición

$$D_{\text{KL}}(p||q) = D_{\text{KL}}(p||q^\star) + D_{\text{KL}}(q^\star||q),$$

con $q^\star$ la proyección de p en $\mathcal{Q}$. Garantiza dirección de mejora y criterio claro de convergencia.

4. **Pasos que respetan la información (gradiente natural).** Actualizar con la métrica de Fisher

$$\dot{\theta} = -I(\theta)^{-1} \nabla_\theta L(\theta)$$

produce trayectorias invariantes a reparametrizaciones: menos zigzag y pasos mejor calibrados.

5. **Puentes con herramientas conocidas.** AIC como riesgo KL esperado; prior de Jeffreys $\pi_J(\theta) \propto \sqrt{\det I(\theta)}$ como volumen Riemanniano; EM y VI como proyecciones alternadas (I/M); teoría *singular* de Watanabe para BIC en modelos no regulares.

Medir el desajuste entre verdad y modelo

La divergencia KL cuantifica el costo de describir p usando q :

$$D_{\text{KL}}(p||q) = \sum_x p(x) \log \frac{p(x)}{q(x)}.$$

No es (necesariamente) simétrica: los errores tienen dirección; no cuesta igual confundir p con q que confundir q con p ¹. Esta asimetría te permite penalizar lo que de verdad importa.

Dos esquemas de actualización (y su lectura actuarial)

Tras ver datos nuevos, quieres acercar q_θ a p . Dos esquemas ampliamente usados —que además coinciden con la *credibilidad*— son:

¹Dicho con humor: *es peor que fafalte a que sosobre*.

1. **Esquema por momentos (Bühlmann–Straub).** Ajustas el modelo para respetar **promedios** o totales confiables (tasa, proporción, total esperado). El estimador clásico combina experiencia propia y base colectiva:

$$\hat{\theta} = Z \bar{X} + (1 - Z) m, \quad Z \in [0, 1].$$

En GI se lee como una *e-proyección* (preserva momentos) que minimiza KL bajo restricciones de expectativa.

2. **Esquema conservador (credibilidad bayesiana).** Cambias lo necesario según la evidencia manteniendo razonable la incertidumbre global. Con conjugadas aparece

$$E[\theta | x] = \frac{n}{n+k} \bar{X} + \frac{k}{n+k} m,$$

con n tamaño muestral y k la fuerza a priori. En GI se interpreta como una *m-proyección* (recta en parámetros naturales).

No compiten: son herramientas complementarias, y GI aclara qué conserva cada una y por qué combinarlas (EM/VI) funciona.

Historia muy breve

De Fisher (información, 1920s) y Jeffreys (prior geométrico, 1946) a Rao (métrica, 1945) y Chentsov (unicidad por invariancia, 1982); Lauritzen y Efron conectan con geometría diferencial; Amari y Nagaoka consolidan la teoría (2000); Eguchi clarifica el rol de divergencias; Akaike (AIC) y Rissanen (MDL) enlazan con selección de modelos; Watanabe desarrolla el aprendizaje singular (2009). La síntesis: *invariancia + divergencias + dualidad* como gramática común para inferencia, aprendizaje y decisión.

Flujo de trabajo honesto

1) Propón una familia (conocimiento del dominio, máximo de entropía, catálogos estándar). 2) Mide *ajuste + curvatura* (log-verosimilitud + volumen de Fisher). 3) Compara familias y elige la que minimiza la *complejidad estocástica*. 4) Optimiza con gradiente natural si el problema es grande. GI no inventa la familia: te da una regla invariante para comparar y moverte dentro de ella.

Qué no hace GI

No predice por ti, no elige priors por ti, no garantiza que tu familia contenga la verdad. Lo que sí hace: te da el *único* metro Riemanniano compatible con invariancia, rutas rectas bien definidas, y penalizaciones de complejidad que dependen de la *forma* del espacio de hipótesis.

Prerrequisitos (y cómo comprobarlos)

Necesitas cálculo multivariable (derivadas, Jacobianos), álgebra lineal (autovalores, definidas positivas), probabilidad (esperanza, verosimilitud, familias exponenciales) y algo de ecuaciones diferenciales (curvas integrales). En el Capítulo 0 (*Prerrequisitos.tex*) encontrarás ejercicios con solución corta para que valides en 1–2 horas si estás listo para arrancar. Si no, el mismo capítulo te apunta a un repaso rápido.

Itinerario del libro (a vista de pájaro)

-
- *Cap. 1–2:* Métrica de Fisher desde cero, volumen y divergencias; Gaussiana como laboratorio.
 - *Cap. 3:* Dualidad e/m , teorema de proyección y pitagórico de KL.
 - *Cap. 4:* Gradiente natural e invariancia en optimización.
 - *Cap. 5:* Modelos singulares, WBIC y selección con curvatura.
 - *Cap. 6:* Credibilidad, máximo de entropía y conexiones bayesianas.
 - *Cap. 7:* Casos prácticos (mixturas, GLMs, redes neuronales, aprendizaje federado).

Si este prólogo tiene una tesis es simple: no necesitamos *saber* dónde está la verdad para trabajar con rigor; necesitamos una geometría que no se deje engañar por coordenadas y que convierta *ajuste + forma del espacio* en una única medida operativa.

Que tu gradiente sea suave y tu sorpresa, cada vez menor.

Capítulo 0: Ejercicios de prerrequisitos

(con respuestas al final de cada ejercicio)

0.1 Álgebra lineal

Importancia. Provee el idioma para modelar espacios de distribuciones y parámetros: ortogonalidad, proyecciones y descomposiciones son la base de la geometría de Fisher y de algoritmos numéricos.

Espacios vectoriales, bases y cambio de base

1. Sea $B = \{(1, 0, 1), (0, 1, 1), (1, 1, 0)\}$ en $\mathbb{R}^3$. ¿Es base? **Resp.:** Sí; el determinante de la matriz con columnas B es $-2 \neq 0$.
2. Expresa $v = (2, 1, 1)$ en coordenadas de la base estándar y en la base B . **Resp.:** En estándar ya es $(2, 1, 1)$; en B , resuelva $[v]_B$ y obtiene $(1, 1, 1)$.
3. Cambie coordenadas: si $[x]_B = (a, b, c)$, encuentre x en la base estándar. **Resp.:** $x = a(1, 0, 1) + b(0, 1, 1) + c(1, 1, 0) = (a + c, b + c, a + b)$.

Productos internos, normas, ortogonalidad y proyecciones

1. Proyección de $y = (1, 2)$ sobre $u = (2, 0)$ en $\mathbb{R}^2$. **Resp.:** $\text{proj}_u(y) = \frac{\langle y, u \rangle}{\langle u, u \rangle} u = \frac{2}{4}(2, 0) = (1, 0)$.
2. Ortonormalice $\{(1, 1), (1, -1)\}$. **Resp.:** $e_1 = \frac{1}{\sqrt{2}}(1, 1)$, $e_2 = \frac{1}{\sqrt{2}}(1, -1)$.
3. Verifique $\|x\|^2 = \|\text{proj}_U x\|^2 + \|x - \text{proj}_U x\|^2$ para $x = (1, 2)$ y $U = \text{span}\{(1, 0)\}$. **Resp.:** $5 = 1^2 + 2^2 = 1^2 + 2^2$ (se cumple).

Autovalores/autovectores, descomposición espectral y SVD

1. Autovalores de $A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$. **Resp.:** $\lambda_1 = 3$, $\lambda_2 = 1$.
2. Diagonalice A anterior. **Resp.:** $A = Q \text{diag}(3, 1) Q^T$ con $Q = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$.
3. SVD de $M = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}$. **Resp.:** $U = V = I$, $\Sigma = \text{diag}(3, 1)$.

Matrices simétricas/definidas positivas, traza y determinante

1. Muestre que $A^T A$ es semidefinida positiva. **Resp.:** $x^T A^T A x = \|Ax\|^2 \geq 0$.

2. Para $B = \begin{pmatrix} 1 & 2 \\ 2 & 5 \end{pmatrix}$, calcule $\det B$ y $\operatorname{tr} B$. **Resp.:** $\det = 1 \cdot 5 - 4 = 1$, $\operatorname{tr} = 6$ (PD).
3. Compruebe positividad definida de B por autovalores. **Resp.:** Autovalores $= \frac{6 \pm \sqrt{36-4}}{2} = 3 \pm \sqrt{5} > 0$.

Cálculo matricial (traza, gradientes) y pseudoinversa

1. Gradiente de $f(x) = x^T B x$ (simétrica). **Resp.:** $\nabla f(x) = 2Bx$.
2. Derive $\frac{\partial}{\partial X} \operatorname{tr}(AXX^T) = ?$ **Resp.:** $(A + A^T)X$ (si A fijo).
3. Pseudoinversa de uv^T con $u, v \neq 0$. **Resp.:** $(uv^T)^+ = \frac{1}{\|u\|^2 \|v\|^2} v u^T$.

0.2 Cálculo multivariable

Importancia. Gradientes y Hessianas describen curvatura de divergencias y la métrica de Fisher; Taylor y cambio de variables aparecen en aproximaciones y estimadores.

Gradiente, Hessiana y Taylor de segundo orden

1. Para $f(x, y) = x^2 + xy + y^2$, halle ∇f y $\nabla^2 f$. **Resp.:** $\nabla f = (2x + y, x + 2y)$; $\nabla^2 f = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$.
2. Aproximación de Taylor de $\log(1+t)$ en $t=0$ hasta orden 2. **Resp.:** $t - \frac{t^2}{2}$.
3. Determine si f es convexa. **Resp.:** Sí; Hessiana $\succeq 0$ (autovalores 1, 3).

Regla de la cadena y jacobianos

1. Jacobiano de $F(x, y) = (x^2 - y, xy)$. **Resp.:** $JF = \begin{pmatrix} 2x & -1 \\ y & x \end{pmatrix}$.
2. Si $g(u, v) = (u + v, uv)$ y $h(x, y) = (x^2, y)$, compute $J(g \circ h)$ en $(1, 1)$. **Resp.:** $J_h = \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}$,
 $J_g = \begin{pmatrix} 1 & 1 \\ v & u \end{pmatrix} \big|_{(u,v)=(1,1)} = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$; producto $= \begin{pmatrix} 2 & 1 \\ 2 & 1 \end{pmatrix}$.
3. Derive $\frac{d}{dt} f(h(t))$ para $f(x, y) = x^2 + y$, $h(t) = (t, t^2)$. **Resp.:** $\frac{d}{dt}(t^2 + t^2) = 2t + 2t = 4t$.

Óptimos de primer/segundo orden

1. Minimice $f(x) = x^4 - 2x^2$. Puntos críticos y tipo. **Resp.:** $f'(x) = 4x^3 - 4x = 4x(x^2 - 1)$; mínimos en $x = \pm 1$, máximo local en $x = 0$.
2. Condición de segundo orden para mínimo en x^* . **Resp.:** $\nabla f(x^*) = 0$ y $\nabla^2 f(x^*) \succ 0$.
3. Minimice $\frac{1}{2} \|Ax - b\|^2$ y dé solución normal. **Resp.:** $A^T A x = A^T b$.

Cambio de variables en integrales

1. Integre $\int_{x^2+y^2 \leq 1} (x^2 + y^2) dx dy$ con polares. **Resp.:** $\int_0^{2\pi} \int_0^1 r^2 r dr d\theta = \pi/2$.
2. Sustitución $u = xy$ en $\int_0^1 \int_0^1 e^{xy} dx dy$ (idea). **Resp.:** Valor = $\sum_{k \geq 0} \frac{1}{(k+1)!} = e - 1$.
3. Jacobiano de $(r, \theta) \mapsto (r \cos \theta, r \sin \theta)$. **Resp.:** $J = r$.

Función implícita (nociones)

1. Para $F(x, y) = x^2 + y^2 - 1 = 0$, halle $\frac{dy}{dx}$ en $(\frac{\sqrt{2}}{2}, \frac{\sqrt{2}}{2})$. **Resp.:** $y' = -\frac{x}{y} = -1$.
2. ¿Se puede resolver $y(x)$ cerca de $(0, 1)$ para F anterior? **Resp.:** Sí, $\partial F / \partial y = 2y \neq 0$ en $(0, 1)$.
3. Para $F(x, y) = y - e^{x+y} = 0$, calcule $y'(0)$ si $y(0) = 0$. **Resp.:** $1 - (1 + y') = 0 \Rightarrow y' = -0 = 0$.

0.3 Probabilidad (convergencias, LLN/CLT)

Importancia. La noción de límite de distribuciones, leyes fuertes y centrales subyace a las aproximaciones locales (LAN) y a la curvatura informativa.

Espacio de probabilidad, variables aleatorias

1. Dado un dado justo, $P(X = k) = 1/6$, halle $E[X]$. **Resp.:** $E[X] = 3,5$.
2. Para $X \sim \text{Bern}(p)$, calcule $P(X = 1)$ y $E[X]$. **Resp.:** p y p .
3. Halle la cdf de $X \sim \text{Unif}[0, 1]$. **Resp.:** $F(x) = 0$ si $x < 0$, x en $[0, 1]$, 1 si $x > 1$.

Esperanza, varianza, covarianza, condicional

1. Si $X \sim \text{Poisson}(\lambda)$, $E[X]$ y $\text{Var}(X)$. **Resp.:** Ambos = λ .
2. Para (X, Y) con $E[X] = E[Y] = 0$, $\text{Cov}(X, Y) = \rho$, halle $\text{Var}(X+Y)$. **Resp.:** $\text{Var}(X) + \text{Var}(Y) + 2\rho$.
3. $E[X | X + Y]$ con $X, Y \sim \mathcal{N}(0, 1)$ indep. **Resp.:** $\frac{1}{2}(X + Y)$.

Modos de convergencia

1. Muestre que $X_n \rightarrow c$ en probabilidad si $P(|X_n - c| > \varepsilon) \rightarrow 0$. **Resp.:** Definición.
2. Si $X_n \rightarrow c$ c.s., entonces $X_n \rightarrow c$ en prob. **Resp.:** Cierto; c.s. $\Rightarrow$ en prob.
3. Si $X_n \Rightarrow X$ y $a_n \rightarrow a$, entonces $a_n X_n \Rightarrow aX$. **Resp.:** Cierto.

LLN y CLT

1. Para $X_i \sim \text{Bern}(p)$, $\bar{X}_n \xrightarrow{a.s.} p$. **Resp.:** Ley fuerte.
2. Aproximar $P(\bar{X}_{100} \leq p + 0,1)$ por CLT. **Resp.:** $\Phi\left(\frac{0,1\sqrt{100}}{\sqrt{p(1-p)}}\right)$.
3. Si $X_i \sim \mathcal{N}(\mu, \sigma^2)$, distribución de $\sqrt{n}(\bar{X}_n - \mu)$. **Resp.:** $\mathcal{N}(0, \sigma^2)$.

Herramientas asintóticas (nociones)

1. (Slutsky) Si $X_n \Rightarrow X$ y $Y_n \xrightarrow{p} c$, $iX_n + Y_n \Rightarrow X + c$? **Resp.:** Sí.
2. (Cramér–Wold) Convergencia de $Z_n \Rightarrow Z$ en $\mathbb{R}^k$. **Resp.:** Equivalente a $a^T Z_n \Rightarrow a^T Z$ para todo a .
3. (Delta) Si $\sqrt{n}(\hat{\theta}_n - \theta) \Rightarrow \mathcal{N}(0, V)$, dé la ley de $\sqrt{n}(g(\hat{\theta}_n) - g(\theta))$. **Resp.:** $\mathcal{N}(0, g'(\theta)Vg'(\theta)^T)$.

0.4 Estadística matemática

Importancia. Fija el puente entre modelos y datos: verosimilitud, información y eficiencia son el esqueleto geométrico del aprendizaje.

Verosimilitud y MLE; consistencia y normalidad

1. MLE para p en $X_i \sim \text{Bern}(p)$. **Resp.:** $\hat{p} = \bar{X}_n$.
2. MLE de μ con $X_i \sim \mathcal{N}(\mu, \sigma^2)$ conocida. **Resp.:** $\hat{\mu} = \bar{X}_n$.
3. Asintóticamente, $\sqrt{n}(\hat{\mu} - \mu) \Rightarrow \mathcal{N}(0, \sigma^2)$. **Resp.:** Sí (CLT).

Información de Fisher y Cramér–Rao

1. Para $\text{Bern}(p)$, $I(p) = \frac{1}{p(1-p)}$. **Resp.:** Derivando ℓ y tomando esperanza.
2. Cota CR para estimadores insesgados de p . **Resp.:** $\text{Var}(\hat{p}) \geq \frac{p(1-p)}{n}$.
3. Para $\text{Poisson}(\lambda)$, $I(\lambda) = \frac{1}{\lambda}$. **Resp.:** Sí.

Suficiencia (Fisher–Neyman) y Rao–Blackwell

1. Muestre que $\sum X_i$ es suficiente en $\text{Poisson}(\lambda)$. **Resp.:** Factorización.
2. Mejore $\hat{\lambda} = X_1$ usando RB. **Resp.:** $E[X_1 \mid \sum X_i] = \frac{1}{n} \sum X_i$.
3. Completez y UMVU en Bernoulli para $\bar{X}_n$. **Resp.:** $\bar{X}_n$ es UMVU de p .

Contrastes: Neyman–Pearson y razón de verosimilitudes

1. Test óptimo para $H_0 : p = p_0$ vs $H_1 : p = p_1$ en Bernoulli. **Resp.:** Umbral sobre $\sum X_i$ (LR).
2. Nivel α mediante cuantiles binomiales. **Resp.:** Elegir k tal que $P_{p_0}(\sum X_i \geq k) \leq \alpha$.
3. LR para $\mathcal{N}(\mu, \sigma^2)$ con σ conocida. **Resp.:** Basado en $\bar{X}$.

Intervalos y pruebas de Wald/score/LR

1. IC 95 % para μ con σ conocida. **Resp.:** $\bar{X} \pm 1,96 \sigma / \sqrt{n}$.
2. Estadístico de Wald para $\mu = \mu_0$. **Resp.:** $W = \frac{(\bar{X} - \mu_0)^2}{\sigma^2/n}$.
3. Prueba LR para p en Bernoulli. **Resp.:** $-2 \log \Lambda \approx \chi_1^2$.

Familias exponenciales

1. Escriba Bernoulli en forma exponencial. **Resp.:** $p(x | \eta) = \exp\{x\eta - \psi(\eta)\}$ con $\eta = \log \frac{p}{1-p}$.
2. Suficiencia canónica. **Resp.:** $T(x) = x$ y $\sum X_i$.
3. Momentos por $\psi'(\eta)$ y $\psi''(\eta)$. **Resp.:** $E[T] = \psi'(\eta)$, $\text{Var}(T) = \psi''(\eta)$.

Distribuciones mixtas

1. Media y varianza de mezcla $\pi \mathcal{N}(\mu_1, \sigma^2) + (1 - \pi) \mathcal{N}(\mu_2, \sigma^2)$. **Resp.:** $E[X] = \pi\mu_1 + (1 - \pi)\mu_2$, $\text{Var} = \sigma^2 + \pi(1 - \pi)(\mu_1 - \mu_2)^2$.
2. Posterior de componente con regla de Bayes. **Resp.:** $P(Z = 1 | x) = \frac{\pi \phi(x; \mu_1, \sigma^2)}{\pi \phi_1 + (1 - \pi) \phi_2}$.
3. Paso E de EM: $\gamma_i = P(Z_i = 1 | x_i)$. **Resp.:** Fórmula anterior por dato i .

0.5 Análisis convexo y optimización

Importancia. La geometría de divergencias es convexa; proyecciones e identidades de Fenchel/Bregman estructuran algoritmos y geodésicas duales.

Conjuntos/funciones convexas; fuerte convexidad y Lipschitz

1. Muestre que $f(x) = e^x$ es convexa. **Resp.:** $f''(x) = e^x \geq 0$.
2. Para $f(x) = \frac{1}{2}x^T Qx$ con $Q \succeq mI$, constate m -fuerte convexidad. **Resp.:** $\nabla^2 f = Q \succeq mI$.
3. Para ∇f L -Lipschitz de $f(x) = \frac{1}{2}x^T Qx$, dé L . **Resp.:** $L = \lambda_{\max}(Q)$.

0.6 Geometría diferencial

Importancia. Modela espacios de distribuciones como variedades con métricas (Fisher) y conexiones; geodésicas = interpolaciones “rectas” en el espacio estadístico.

Variedades suaves, cartas y atlas

1. Verifique que $S^1 = \{(x, y) : x^2 + y^2 = 1\}$ es 1-variedad. **Resp.:** Cubrir con cartas $y > 0$ y $y < 0$ vía proyección.
2. Carta estereográfica de S^1 (desde $(0, 1)$). **Resp.:** $\phi(x, y) = \frac{x}{1-y}$.
3. Atlas mínimo para S^1 . **Resp.:** Dos cartas como arriba.

Espacios tangentes, pushforward/pullback

1. Derivada de $F(x, y) = (x^2 - y, xy)$ en $(1, 1)$. **Resp.:** $dF = \begin{pmatrix} 2 & -1 \\ 1 & 1 \end{pmatrix}$.
2. Pushforward de $v = (1, 0)$ bajo F anterior. **Resp.:** $(2, 1)$.
3. Pullback de 1-forma $\omega = udx + vdy$ por F (idea). **Resp.:** $F^*\omega = \omega \circ dF$.

Métrica Riemanniana, gradiente y geodésicas

1. En $\mathbb{R}^2$ con métrica $G = I$, gradiente de $f = \frac{1}{2}\|x\|^2$. **Resp.:** $\nabla f = x$.
2. Geodésicas en $\mathbb{R}^2$ euclidiano. **Resp.:** Rectas $\gamma(t) = x_0 + tv$.
3. Longitud de $\gamma(t) = (t, t^2)$ en $[0, 1]$. **Resp.:** $\int_0^1 \sqrt{1 + 4t^2} dt = \frac{1}{2}(\sqrt{5} + \operatorname{asinh} 2)$.

Conexión de Levi-Civita, curvatura y mapa exponencial

1. En $\mathbb{R}^n$ euclidiano, calcule símbolos de Christoffel. **Resp.:** Todos $\Gamma_{ij}^k = 0$.
2. Exponencial en $\mathbb{R}^n$. **Resp.:** $\exp_x(v) = x + v$.
3. Curvatura seccional en $\mathbb{R}^n$. **Resp.:** 0.

Invariancia por reparametrizaciones

1. La longitud de curva es invariante bajo reparametrización monótona. **Resp.:** Se preserva por cambio de variable.
2. Compruebe que el gradiente depende de la métrica, no de coordenadas. **Resp.:** Objeto geométrico.
3. Demuestre que div cambia con densidad pero es tensorial. **Resp.:** Identidad de transformación.

0.7 Teoría de la información

Importancia. Entropía y divergencias cuantifican “distancia” entre distribuciones; KL induce la métrica de Fisher y proyecciones que estructuran la geometría.

Entropía, entropía cruzada y KL

1. Entropía de Bern(p). **Resp.:** $H(p) = -p \log p - (1-p) \log(1-p)$.
2. $D_{\text{KL}}(\text{Bern}(p) \parallel \text{Bern}(q))$. **Resp.:** $p \log \frac{p}{q} + (1-p) \log \frac{1-p}{1-q}$.
3. Relación $H(p, q) = H(p) + D_{\text{KL}}(p \parallel q)$. **Resp.:** Verdadera.

Información mutua y reglas de cadena

1. Para canal BSC(ε) con $X \sim \text{Bern}(1/2)$, $I(X; Y) = ?$ **Resp.:** $1 - h_2(\varepsilon)$.
2. Regla de cadena: $I(X; Y, Z) = I(X; Y) + I(X; Z \mid Y)$. **Resp.:** Cierta.
3. $I(X; X) = H(X)$. **Resp.:** Cierto.

Desigualdad de procesamiento de datos

1. Si $X \rightarrow Y \rightarrow Z$, ¿ $I(X; Z) \leq I(X; Y)$? **Resp.:** Sí.
2. Para BSC seguida de BSC, calcule I total. **Resp.:** $1 - h_2(\varepsilon \star \delta)$, con $\varepsilon \star \delta = \varepsilon(1-\delta) + (1-\varepsilon)\delta$.
3. KL contraída por canal estocástico. **Resp.:** $D(PK \parallel QK) \leq D(P \parallel Q)$.

f -divergencias

1. Hellinger entre Bernoulli(p) y (q). **Resp.:** $H^2 = 1 - \sqrt{pq} - \sqrt{(1-p)(1-q)}$.
2. χ^2 entre Poisson(λ) y Poisson(μ). **Resp.:** $\chi^2 = \exp((\lambda - \mu)^2 / \mu) - 1$.
3. Jensen–Shannon para Bernoulli simétrica p y $1-p$. **Resp.:** $\text{JS} = \frac{1}{2}(H(p) + H(1-p)) - H(1/2)$.

Familias exponenciales y momentos

1. Para Poisson, $\eta = \log \lambda$. Dé $\psi(\eta)$. **Resp.:** $\psi(\eta) = e^\eta$.
2. $E[X] = \psi'(\eta)$ y $\text{Var}(X) = \psi''(\eta)$. **Resp.:** Ambos $= e^\eta = \lambda$.
3. Suficiencia natural. **Resp.:** $T = \sum X_i$.

0.8 Procesos estocásticos

Importancia. Modelan secuencias dependientes y dinámica de aprendizaje; ergodicidad fundamenta promedios de largo plazo y MCMC.

Cadenas de Markov en tiempo discreto

1. Para $P = \begin{pmatrix} 0,9 & 0,1 \\ 0,2 & 0,8 \end{pmatrix}$, halle P^2 . **Resp.:** $\begin{pmatrix} 0,83 & 0,17 \\ 0,34 & 0,66 \end{pmatrix}$.
2. Distribución tras 3 pasos desde $\pi_0 = (1, 0)$. **Resp.:** $\pi_0 P^3$ (numéricamente $\approx (0,778, 0,222)$).
3. Probabilidad de regresar al estado 1 en 2 pasos. **Resp.:** $(P^2)_{11} = 0,83$.

Estacionaria, ergodicidad y mezcla

1. Estacionaria π de P anterior. **Resp.:** $\pi = (2/3, 1/3)$.
2. ¿Es irreducible y aperiódica? **Resp.:** Sí.
3. Límite $\pi_0 P^n \rightarrow \pi$. **Resp.:** Sí.

Reversibilidad y balance detallado

1. Verifique $\pi_i P_{ij} = \pi_j P_{ji}$ para $\pi = (2/3, 1/3)$. **Resp.:** $\frac{2}{3}0,1 = \frac{1}{3}0,2$ y $\frac{2}{3}0,9 = \frac{1}{3}0,8$ (cierto).
2. Reversibilidad implica estacionaria. **Resp.:** Sí.
3. Construya P reversible dado π . **Resp.:** $P_{ij} = \frac{w_{ij}}{\pi_i}$ con $w_{ij} = w_{ji} \geq 0$, $\sum_j w_{ij} = \pi_i$.

LLN en cadenas ergódicas (nociones)

1. Para función f , $\frac{1}{n} \sum f(X_k) \rightarrow E_\pi[f]$. **Resp.:** Sí (LLN ergódico).
2. En P anterior y $f(1) = 0, f(2) = 1$, calcule el límite. **Resp.:** $E_\pi[f] = 1/3$.
3. Tiempo de mezcla aproximado: evalúe $\|\pi_0 P^n - \pi\|_{TV}$. **Resp.:** Decae geométricamente con razón el segundo autovalor (0,7).

MCMC (transiciones e invarianza)

1. Aceptación de Metropolis–Hastings: $\alpha(x, y) = \min\{1, \frac{\pi(y)q(y,x)}{\pi(x)q(x,y)}\}$. **Resp.:** Fórmula dada.
2. Para propuesta simétrica, simplifique α . **Resp.:** $\alpha = \min\{1, \pi(y)/\pi(x)\}$.
3. Verifique que el kernel tiene invariante π . **Resp.:** Por balance detallado.

0.9 Programación científica

Importancia. Implementa algoritmos geométricos y estadísticos con estabilidad y reproducibilidad.

NumPy: arreglos, broadcasting y álgebra lineal

1. (Código) Multiplique una matriz 2×2 por un vector. **Resp.:** `A@x` con `A=np.array([[1,2],[3,4]])`, `x=np.array([1,1])` da `[3,7]`.
2. (Código) Norma de x . **Resp.:** `np.linalg.norm(x)`.
3. (Código) SVD. **Resp.:** `U, S, Vt = np.linalg.svd(A)`.

SciPy: integración, optimización y stats

1. (Código) Integrar e^{-x^2} . **Resp.:** `quad(lambda x: np.exp(-x**2), -np.inf, np.inf) =  $\sqrt{\pi}$` .
2. (Código) Minimizar $x^4 - 2x^2$. **Resp.:** `minimize` con inicio 0 retorna $x = \pm 1$.
3. (Código) CLT simulado. **Resp.:** `np.mean(np.random.randn(n))` para muchos n .

Automatización y reproducibilidad

1. Semilla fija. **Resp.:** `np.random.seed(0)`.
2. Entornos. **Resp.:** `requirements.txt` o `conda env`.
3. Guardar arrays. **Resp.:** `np.save('a.npy', A)`.

Visualización básica (matplotlib)

1. (Código) Curva de $y = \sin x$. **Resp.:** `plt.plot(x, np.sin(x))`.
2. (Código) Histograma. **Resp.:** `plt.hist(data)`.
3. (Código) Etiquetas. **Resp.:** `plt.xlabel('x'); plt.ylabel('y')`.

0.10 Métodos numéricos para optimización

Importancia. Permiten resolver proyecciones y estimación en variedades, y seguir geodésicas/flows definidos por divergencias.

Descenso por gradiente, line search y parada

1. Un paso de GD para $f(x) = \frac{1}{2}\|Ax - b\|^2$ con η . **Resp.:** $x^+ = x - \eta A^T(Ax - b)$.
2. Paso óptimo sobre dirección d en cuadrática Q . **Resp.:** $\eta^* = \frac{d^T \nabla f}{d^T Q d}$.
3. Criterio de parada. **Resp.:** $\|\nabla f(x)\| \leq \varepsilon$.

Newton y quasi-Newton (BFGS/L-BFGS)

1. Paso de Newton. **Resp.:** $x^+ = x - [\nabla^2 f(x)]^{-1} \nabla f(x)$.
2. Actualización BFGS. **Resp.:** $H_{k+1} = (I - \rho s y^T) H_k (I - \rho y s^T) + \rho s s^T$, $\rho = 1/(y^T s)$.
3. Ventaja de L-BFGS. **Resp.:** Memoria limitada (usa parejas (s, y)).

Métodos estocásticos (SGD, momentum)

1. Actualización SGD. **Resp.:** $x^+ = x - \eta \widehat{\nabla f}(x)$ (mini-lote).
2. Momentum clásico. **Resp.:** $v^+ = \beta v + \nabla f(x)$; $x^+ = x - \eta v^+$.
3. Regla Adam (forma básica). **Resp.:** Acumulados m, v y correcciones de sesgo; $x^+ = x - \alpha m/(\sqrt{v} + \varepsilon)$.

Proyección, penalizaciones y barreras

1. Proyección sobre caja $[l, u]$. **Resp.:** $\Pi_{[l, u]}(x) = \min(\max(x, l), u)$ (componente a componente).
2. Penalización cuadrática para $Ax = b$. **Resp.:** Minimizar $f(x) + \frac{\rho}{2} \|Ax - b\|^2$.
3. Barrera logarítmica para $x > 0$. **Resp.:** $f(x) - \mu \sum_i \log x_i$.

Condicionamiento y estabilidad

1. Número de condición de $A = \begin{pmatrix} 1 & 0 \\ 0 & \kappa \end{pmatrix}$. **Resp.:** $\kappa(A) = \kappa$ (norma 2).
2. Sensibilidad de $Ax = b$ a δb . **Resp.:** $\frac{\|\delta x\|}{\|x\|} \lesssim \kappa(A) \frac{\|\delta b\|}{\|b\|}$.
3. Regularización de Tikhonov. **Resp.:** Minimizar $\|Ax - b\|^2 + \lambda \|x\|^2$.